Паддинг и метка начала истории в тензорных последовательных рекомендациях

1. Задача, цель и гипотезы

1.1 Задача

Даны хронологически упорядоченные неявные взаимодействия пользователей с объектами из каталога. На каждом контрольном моменте требуется ранжировать объекты каталога, с которыми пользователь ещё не взаимодействовал до этого момента, и предсказать следующий объект.

Для пользователя u пусть $s_u = (i_1, \ldots, i_{n_u})$ — последовательность дедуплицированных взаимодействий в порядке времени. При максимальной длине K используется хвост из не более чем K реальных событий. Когда $n_u < K$, исходное представление [1] выравнивает хвост по последней позиции, добавляя нулевые значения слева. В тензорной постановке ноль означает отсутствие наблюдаемой единицы в данной ячейке, а не отдельный наблюдаемый класс «не купил этот товар».

Цель — проверить, помогает ли модели явно передать информацию о доступной длине истории, и как это влияет на качество, вычислительную стоимость и корректность разреженной реализации LA-SATF. Выводы ограничиваются выбранными датасетами, временным протоколом, длиной K, вариантом преобразования рейтингов и настройками модели.

1.2 Гипотезы и оцениваемые контрасты

H1 (качество): PAD и BOS повышают NDCG@10 относительно Zero; прирост может быть больше для коротких доступных историй.

H2 (стоимость/качество): повторяемый PAD дороже Zero и BOS по времени из-за нескольких ненулевых позиций специального объекта; BOS может сохранить качество при меньших затратах, чем PAD.

H3 (зависимость от длины): эффект кодировки различается между историями разной длины.

2. Существующие решения и самостоятельный вклад

Frolov и Oseledets вводят sequence-aware tensor factorization, Hankel-развёртку позиционных векторов и LA-SATF с локальной причинной позиционной обработкой [1]. В исходной постановке [1] короткие последовательности выравниваются по последней позиции и дополняются нулевым префиксом. Авторы прямо отмечают, что специальный токен вместо нуля возможен, но требует особой обработки разреженных вычислений, и оставляют его изучение для дальнейшей работы.

Проект использует авторский код SATF как отправную точку [2], но не предполагает, что любая модификация токенов автоматически поддерживается кодом. Самостоятельный вклад команды — (i) формальное и согласованное определение Zero/PAD/BOS для обучения и инференса; (ii) реализация и проверка операций для повторяющихся PAD; (iii) корректный сравнительный эксперимент с анализом по длинам истории и оценкой затрат ресурсов.

3. Предлагаемый метод

3.1 Представления историй

Сравниваются три кодировки одной и той же последовательности из $n \le K$ реальных событий. Пусть K — число слотов для истории, а $q = K - n$ — размер отсутствующего префикса при неполной истории:

Вариант	Кодировка истории	Смысл
Zero	$[0, \ldots, 0, i_1, \ldots, i_n]$ с q нулями	Исходное кодирование отсутствующих наблюдений [1].
PAD	$[\text{PAD}, \ldots, \text{PAD}, i_1, \ldots, i_n]$ с q токенами	Каждая незаполненная позиция — положительное наблюдение отдельного служебного объекта.
BOS	$[0, \ldots, 0, \text{BOS}, i_1, \ldots, i_n]$ с $q - 1$ нулями, одним BOS и n реальными событиями; всего K слотов	Один токен сообщает границу начала доступной истории; остаток слева — нулевой префикс.

В формулах выше $q = K - n$. Для Zero и PAD это q пустых префиксных слотов; для BOS один из этих слотов занимает BOS, поэтому остаётся $q - 1$ нулевых слотов. (Следовательно, BOS в фиксированном окне K определён только при $n < K$.) При $n = K$ метка BOS не добавляется, и все три варианта совпадают. Ни PAD, ни BOS не являются кандидатами рекомендации.

3.2 Обучение

LA-SATF строит из позиционного тензора четырёхмерное Hankel-представление и приближает его Tucker-разложением:

$$\mathcal{Y}^{(c)} = \bar{\mathcal{X}}^{(c)} \times_3 A_L^T,$$
$$\min_{G,\,U,\,V,\,W_L,\,W_S} \|\mathcal{Y}^{(c)} - G \times_1 U \times_2 V \times_3 W_L \times_4 W_S\|_F^2.$$

Здесь c — Zero, PAD или BOS; обучение выполняется методом ALS/HOOI, как в [1]. Нормализация популярности учитывается при построении $\bar{\mathcal{X}}^{(c)}$. Zero оставляет пустые позиции нулевыми. PAD и BOS добавляют положительные записи служебного объекта, поэтому их нельзя просто вставить в разреженный код без проверки. Особенно для повторяющегося PAD нужно учесть все его позиции при Hankel-операциях.

4. Данные и протокол оценки

Используем **MovieLens-1M** [4] и **Amazon Beauty 2014 (5-core)** [5], как в исходной статье. Оба датасета содержат идентификаторы пользователя и объекта, оценку и время взаимодействия. В MovieLens-1M объекты - фильмы; для них доступны название, год выпуска и жанры. Описаний сюжета и изображений в датасете нет. В Amazon Beauty объекты - косметические товары и средства ухода; файл взаимодействий дополнительно содержит тексты и заголовки отзывов. Отдельно опубликованы метаданные товаров: названия, описания, категории, бренды, цены и ссылки на изображения, а также готовые визуальные признаки. В проекте используем идентификаторы объектов и хронологию взаимодействий; тексты и изображения для выбранного метода не требуются. **Вход модели** - история объектов пользователя в хронологическом порядке. **Таргет** - следующий новый для пользователя фильм или товар, с которым он взаимодействует.

Основная метрика качества - **NDCG@10**. Также измерим время обучения и инференса модели. Сравним варианты Zero, PAD и BOS для различных длин пользовательской истории. Эксперименты повторим с несколькими случайными инициализациями для проверки устойчивости результатов.

5. Бейзлайны и эксперименты

Бейзлайны: SASRec [3] и исходная LA-SATF с нулевым паддингом (Zero) [1]. В экспериментах сравним варианты Zero, PAD и BOS и будем варьировать настройки LA-SATF: ранги разложения, размер локального окна, затухание позиционных весов и нормализацию популярности.

6. План, роли, ресурсы и риски

Срок	Задача и результат	Ответственный
23 октября - 18 ноября	Подготовка данных и протокола оценки; прогон SASRec и LA-SATF Zero на MovieLens-1M.	Даниил Деомидов
23 октября - 18 ноября	Реализация и обучение LA-SATF с PAD и BOS на MovieLens-1M.	Никита Ляпин
19 ноября	Первый прогресс-отчёт и презентация.	Совместно
20 ноября - 2 декабря	Прогон бейзлайнов на Amazon Beauty; сравнение метрик и времени работы моделей.	Даниил Деомидов
20 ноября - 2 декабря	Обучение LA-SATF с PAD и BOS на Amazon Beauty; абляции и анализ по длинам историй.	Никита Ляпин
3 декабря	Второй прогресс-отчёт и презентация.	Совместно
4-8 декабря	Сводные результаты и инструкции по запуску бейзлайнов.	Даниил Деомидов
4-8 декабря	Итоговые проверки и инструкции по запуску LA-SATF.	Никита Ляпин
9 декабря	Финальный отчёт и презентация.	Совместно
10-11 декабря	Защита проекта и демонстрация результатов.	Совместно

Вычислительные ресурсы: бесплатные ресурсы Google Colab: CPU для LA-SATF, GPU для SASRec.

Риски и минимальный результат: повторяемый PAD может увеличить расход памяти и время обучения; используем разреженные операции и ограничим ранги разложения. Минимальный результат - воспроизведение LA-SATF и сравнение Zero, PAD и BOS на MovieLens-1M.

Источники

[1] Frolov E., Oseledets I. *Tensor-Based Sequential Learning via Hankel Matrix Representation for Next Item Recommendations.* IEEE Access, 11, 6357-6371, 2023. DOI: 10.1109/ACCESS.2023.3234863.

[2] Авторский код SATF: github.com/recspert/SATF. [3] Kang W.-C., McAuley J. *Self-Attentive Sequential Recommendation.* ICDM, 2018. arXiv:1808.09781.

[4] GroupLens, MovieLens-1M. [5] McAuley Lab, Amazon Reviews 2014: Beauty, 5-core.